

FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO - FECAP

Bacharelado em Ciência da Computação

Projeto Interdisciplinar: Ciência de Dados – Professor Eduardo Savino Gomes

Estudantes:

- André Gregório dos Santos – RA: 24026489
- Guilherme Reis Fogolin de Godoy – RA: 24026241
- Pedro Henrique Nascimento Lemos – RA: 23025380
- Yan Ramos Cezareto – RA: 24026005

Turma: 4NACOMP_S

Entrega 02 - Projeto Interdisciplinar: Ciência de Dados

Preparação dos dados fornecidos pela Pic Money

Objetivo: O objetivo principal desta etapa do projeto é a engenharia e a preparação completa da base de dados da Pic Money, transformando os datasets brutos em uma fonte única de verdade analítica. O estudo visa construir um dataset integrado que correlacione o perfil do usuário (player) com as métricas financeiras da transação (repasse Pic Money, valor de compra e margem). Para tal, o processo envolve detalhadamente as seguintes etapas cruciais: seleção, limpeza/uniformização, derivação de variáveis (KPIs), integração multibases e formatação dos dados para que o arquivo final esteja otimizado e pronto para consumo em dashboards de business intelligence (BI), fornecendo insights robustos para tomadas de decisão estratégicas.

 **Importante!** Devidos scripts e visões estão disponíveis no arquivo do Colab.

Para acesso: [Entrega 02 - Professor Savino](#).

Carregamento das bases de dados

Objetivo: A etapa inicial do projeto consistiu na importação e carregamento dos conjuntos de dados brutos fornecidos pela Pic Money para o ambiente de desenvolvimento, utilizando o Google Colab com a biblioteca Pandas (Python) como principal ferramenta. O objetivo central é unificar essas fontes de informação para criar uma base analítica coesa. A leitura dos arquivos .csv foi realizada especificando o delimitador correto (;), garantindo que os dados estivessem estruturados adequadamente em dataframes para as subsequentes fases de limpeza e engenharia de features.

Bases de dados analisadas

O projeto baseou-se na análise detalhada de três datasets distintos, sendo a integração de seus dados o elemento chave para a criação dos indicadores chave de performance (KPIs) estratégicos:

01. Players (Base cadastral): Contém 10.000 registros de informações cadastrais dos usuários do aplicativo. É a fonte primária para o perfil demográfico (idade, sexo) e hábitos de consumo (categoria frequentada).

02. Transações (Cupons capturados): Registra 100.000 eventos de transações, incluindo as métricas financeiras essenciais para o negócio, como o repasse da empresa, valor do cupom, categoria do estabelecimento e data da transação.

03. Lojas e valores (Massa de teste): Esta base (10.000 linhas) foi crucial para trazer informações detalhadas de valor da compra e valor do cupom por estabelecimento, o que permitiu a derivação da margem de repasse no dataset final.

04. Pedestres (Base simulada): Contém 100.000 registros simulados de potenciais usuários em uma área específica (Avenida Paulista). Esses dados fornecem

um benchmark geográfico e demográfico para entender o potencial de captação de novos players na região.

Verificação da qualidade e limpeza dos dados

Objetivo da Limpeza de Dados: O código desenvolvido tem como objetivo principal garantir a integridade, consistência e confiabilidade dos dados antes de qualquer análise estatística ou integração entre bases. Essa etapa é responsável por carregar, inspecionar, limpar e validar quatro datasets distintos da empresa PicMoney, assegurando que os dados estejam padronizados e prontos para análises subsequentes. O processo foi projetado para identificar valores ausentes, duplicidades, erros de formatação e inconsistências em campos críticos, utilizando técnicas automatizadas e robustas de verificação de qualidade.

1. Carregamento Robusto dos Dados

O processo inicia-se com a importação das bibliotecas essenciais para manipulação e análise de dados — *pandas*, *numpy*, *matplotlib* e *seaborn*, além do módulo *datetime* para o tratamento de colunas temporais.

Em seguida, o script executa uma função denominada `carregar_csv_robusto`, cuja finalidade é tentar diferentes estratégias de leitura de arquivos CSV. Essa função considera múltiplos padrões de separadores e encodings (UTF-8, Latin1, vírgula, ponto e vírgula, tabulação), garantindo a correta importação independentemente da origem ou configuração regional dos arquivos; durante o carregamento, o código exibe mensagens informativas indicando o nome do dataset, a estratégia de leitura utilizada e o número de linhas e colunas carregadas. Essa etapa garante resiliência a arquivos heterogêneos e reduz falhas por incompatibilidade de formato.

Os quatro datasets carregados são:

- Base Cadastral de Players
- Base de Transações - Cupons Capturados
- Base Simulada de Pedestres - Av. Paulista
- Base de Lojas e Valores

Cada dataset é armazenado em um dicionário Python, permitindo manipulação dinâmica e estruturada. Ao final dessa fase, o sistema valida que todos os quatro conjuntos foram carregados corretamente e apresenta suas estruturas iniciais (colunas, tipos de dados e primeiras linhas).

2. Verificação e Limpeza da Qualidade dos Dados

Após o carregamento, inicia-se a etapa de verificação e limpeza sistemática, conduzida pela função `verificar_qualidade`.

Essa função tem como objetivo padronizar e higienizar os dados, assegurando que apenas informações válidas e consistentes sejam mantidas

As ações executadas são as seguintes:

2.1. Análise de Valores Ausentes

O script identifica colunas com valores nulos (NaN) e calcula o percentual de ausência em cada uma delas. Em vez de remover registros de forma indiscriminada, é adotada uma estratégia seletiva, onde apenas linhas que apresentem ausência em colunas críticas (como *celular*, *idade*, *repasse_picmoney* ou *categoria_estabelecimento*) são excluídas.

Essa escolha evita a perda de registros relevantes e preserva a densidade amostral necessária para análises posteriores.

2.2. Análise e Remoção de Duplicatas

O código avalia a existência de registros duplicados dentro de cada dataset, contabilizando e removendo eventuais repetições. Essa etapa garante que cada linha represente uma observação única, prevenindo distorções em métricas agregadas.

2.3. Conversão e Validação de Datas

As colunas temporais — *data*, *data_captura* e *data_ultima_compra* — são convertidas para o tipo `datetime`, assegurando a correta interpretação no formato dia/mês/ano (DD/MM/AAAA).

Durante o processo, o código identifica e reporta datas inválidas (convertidas para NaT) e

apresenta o intervalo temporal válido do dataset, o que facilita a verificação de consistência cronológica.

2.4. Conversão e Validação de Valores Numéricos

Colunas que armazenam informações monetárias ou quantitativas — como *valor_compra*, *valor_cupom*, *repasse_picmoney* e *idade* — são padronizadas para o tipo numérico (`float`).

Para isso, são removidos caracteres não numéricos (como “R\$” e vírgulas decimais) e aplicadas conversões seguras com tratamento de erros. O código também fornece estatísticas descritivas básicas (mínimo, máximo e média), permitindo validar o intervalo e a coerência dos valores.

2.5. Padronização de Campos Textuais

Todos os campos do tipo texto são normalizados com remoção de espaços em branco e conversão consistente de tipos.

A coluna *celular*, usada como chave primária em várias bases, recebe tratamento especial, garantindo unicidade e padronização para integração futura entre datasets.

Ao término, o sistema imprime um resumo quantitativo da limpeza, informando:

- Quantidade inicial e final de registros;
- Percentual de dados mantidos;
- Memória utilizada antes e após o processo.

3. Aplicação da Limpeza em Todos os Datasets

Após a definição da função de verificação, o código aplica o processo a cada um dos quatro datasets, de forma individualizada e controlada.

Para isso, são definidas **colunas críticas específicas** por tipo de base:

- *Players*: celular, idade, sexo
- *Transações*: data, categoria_estabelecimento, repasse_picmoney, celular
- *Pedestres*: idade, sexo

- *Lojas e Valores:* data_captura, nome_loja, valor_compra, valor_cupom, tipo_loja

Essa abordagem adaptativa garante que cada dataset seja tratado de acordo com sua estrutura e relevância analítica, evitando remoções indevidas ou perda de atributos essenciais.

4. Consolidação e Resumo Final

Como etapa conclusiva, o código gera um **resumo comparativo** que apresenta o número de registros originais e o número de registros após a limpeza para cada dataset, além do percentual de retenção.

O resultado é exibido em formato tabular, permitindo uma leitura clara e objetiva da eficiência do processo.

Todos os datasets resultantes são renomeados com o sufixo `_limpo` (por exemplo, `df_players_limpo`, `df_transacoes_limpo`, etc.), indicando que estão prontos para uso nas etapas seguintes de integração, derivação de indicadores e análise exploratória.

Resultados e Validação

O processo implementado garantiu:

- **100% de sucesso no carregamento** das quatro bases, independentemente do formato de origem;
- **Redução controlada de dados** apenas quando valores críticos estavam ausentes;
- **Conversão consistente** de tipos de dados textuais, numéricos e temporais;
- **Eliminação de duplicidades e padronização das chaves de integração**;
- **Relatórios automatizados** com métricas de memória, porcentagem de registros mantidos e estrutura pós-limpeza.

A execução dessa etapa é essencial para assegurar uma base confiável e analiticamente válida, permitindo a integração posterior entre as bases e a construção de indicadores estratégicos com total rastreabilidade e precisão.

Impacto na Análise Posterior

Com a limpeza concluída, o projeto passa a dispor de datasets padronizados, consistentes e integráveis, o que garante a solidez das análises financeiras, demográficas e comportamentais que serão desenvolvidas nas próximas etapas.

A abordagem seletiva e automatizada utilizada reduz a perda de dados relevantes e aumenta a confiabilidade dos resultados, consolidando essa fase como um pilar fundamental da engenharia de dados do projeto PicMoney.

Integração dos Dados

Objetivo da Integração: Após a conclusão da fase de limpeza e verificação de qualidade dos dados, o próximo passo do processo de engenharia de dados consiste na integração das bases provenientes de diferentes fontes; o objetivo principal desta etapa é unificar os datasets já higienizados — *Players*, *Transações*, *Lojas e Valores* e *Pedestres* — em um único conjunto analítico denominado `df_final`, garantindo coerência entre as informações e preparando os dados para análises estatísticas e cruzamentos entre variáveis; o processo de integração foi estruturado de forma modular, com foco na rastreabilidade e verificação contínua de consistência durante cada junção.

Estrutura Inicial e Diagnóstico dos DataFrames

Antes do início da integração, o código realiza uma inspeção detalhada das estruturas dos quatro datasets limpos (`df_players_limpo`, `df_transacoes_limpo`, `df_lojas_valores_limpo` e `df_pedestres_limpo`).

Nessa etapa, são impressas informações como:

- Número de linhas e colunas (shape) de cada dataset;
- Listagem das colunas disponíveis em cada um;
- Verificação da presença de campos-chave necessários à integração, como a coluna celular.

Esse diagnóstico inicial assegura que todas as bases possuam a estrutura mínima necessária para o processo subsequente e permite identificar eventuais incompatibilidades antes da execução das junções.

Identificação das Colunas de Ligação (Chaves)

O passo seguinte consiste em identificar as chaves de integração entre os datasets, ou seja, as colunas que permitem relacionar os registros de uma base com outra.

O código verifica, de forma automatizada, a existência da coluna celular em cada dataset e contabiliza o número de valores únicos nela contidos.

Essa análise é essencial, pois o campo celular é adotado como chave primária de integração entre *Players*, *Transações* e, eventualmente, *Lojas e Valores*.

Caso algum dataset não possua essa coluna, são definidas estratégias alternativas de relacionamento com base em campos equivalentes, como *categoria_estabelecimento* ou *tipo_loja*.

Esse procedimento reforça a integridade relacional do modelo e previne associações incorretas durante o merge.

Estratégia de Integração

Com base na estrutura das bases, foi definida a seguinte estratégia de junção hierárquica:

1. Integração entre Transações e Players, utilizando a chave comum celular;
2. Junção com o dataset Lojas e Valores, preferencialmente também por celular — caso inexistente, realiza-se um agrupamento alternativo por *tipo_loja* ou *categoria_estabelecimento*;
3. Manutenção da base Pedestres como um dataset independente, utilizada para comparações e análises complementares de comportamento e perfil demográfico.

Essa estrutura modular de integração garante flexibilidade e clareza na vinculação entre as bases, mantendo o histórico e a rastreabilidade de cada origem de dado.

Passo 1: Integração entre Transações e Players

A primeira junção é realizada entre os datasets `df_transacoes_limpo` e `df_players_limpo`.

Inicialmente, o código cria cópias independentes de ambas as bases (`df_trans` e `df_play`) para evitar modificações diretas nos originais.

Em seguida, executa-se uma padronização da chave celular, convertendo-a para o tipo `string` e removendo espaços em branco — medida essencial para garantir a correspondência exata entre os valores das duas tabelas.

Além disso, são eliminadas duplicatas no dataset de Players, de modo que cada número de celular esteja associado a um único registro de jogador.

Após essa preparação, é realizada a junção (*merge*) entre as bases, adotando a estratégia left join, o que assegura que todos os registros de transações sejam mantidos, mesmo quando não houver correspondência em `df_players_limpo`.

O sistema informa a quantidade total de registros, colunas resultantes e a taxa de correspondência entre os datasets, evidenciando a eficiência do vínculo relacional.

Essa etapa consolida as informações cadastrais dos usuários junto aos seus respectivos históricos de transações, gerando o DataFrame `df_integrado_1`.

Passo 2: Integração com a Base de Lojas e Valores

No segundo estágio, busca-se adicionar ao conjunto integrado as informações comerciais e financeiras provenientes da base `df_lojas_valores_limpo`.

O procedimento varia conforme a estrutura do dataset:

1. Caso a base possua a coluna celular:

O código realiza um join direto entre `df_integrado_1` e `df_lojas_valores_limpo`, também por meio da chave celular, garantindo uma integração simples e direta entre os dados transacionais e os dados de lojas.

2. Caso a base não possua a coluna celular:

É executada uma estratégia alternativa de agregação.

Os valores monetários são agrupados por *tipo_loja* (função `groupby`), e para cada tipo são calculadas as estatísticas de média, soma e contagem referentes aos campos *valor_compra* e *valor_cupom*.

Essas informações agregadas são renomeadas e posteriormente associadas à base integrada através de um join por *tipo_loja*, que é mapeado a partir da coluna *categoria_estabelecimento* do dataset de transações.

Essa abordagem garante que mesmo na ausência de uma chave direta (celular), os dados de desempenho comercial das lojas sejam incorporados à análise, preservando a coerência sem comprometer a integridade relacional.

O resultado é um novo DataFrame, denominado `df_final`, contendo a junção entre Transações, Players e Lojas/Valores, pronto para exploração estatística.

Resumo e Validação da Integração

Após a conclusão dos merges, o código gera um resumo automatizado da integração, exibindo:

- Quantidade total de registros e colunas do dataset final (`df_final`);
- Número de celulares únicos;
- Tipos de dados e quantidade de valores nulos por coluna;
- As primeiras cinco linhas da base resultante;
- Estatísticas de completude (percentual de colunas com valores ausentes).

Esse relatório fornece uma visão completa da qualidade da integração e da consistência estrutural da nova base consolidada.

Se nenhuma coluna apresentar valores nulos, o sistema confirma a integridade com uma mensagem de validação positiva

Por fim, o script informa os datasets disponíveis para as etapas seguintes:

- `df_final` → base integrada principal, reunindo transações, informações de usuários e dados de lojas;
- `df_pedestres_limpo` → base complementar para análises comparativas de perfil e comportamento.

Resultados e Conclusão

A etapa de integração dos dados resultou em um dataset unificado, limpo e coerente, apto para utilização em modelos analíticos e dashboards de performance.

As principais conquistas dessa fase incluem:

- Integração relacional bem-sucedida entre múltiplas fontes;
- Eliminação de duplicatas e inconsistências nas chaves de junção;
- Adoção de estratégias alternativas de merge, assegurando completude mesmo em bases sem chaves comuns;
- Geração de relatórios automatizados com informações sobre estrutura, nulos e correspondência.

Com isso, a base consolidada `df_final` torna-se o ponto central de análise do projeto PicMoney, possibilitando estudos sobre o comportamento dos usuários, desempenho das lojas e padrões de transações de forma integrada e confiável.

Derivação

Objetivo: Esta etapa tem como principal objetivo transformar o *dataset integrado* (df_final) em uma base de dados analiticamente enriquecida, por meio da criação de variáveis derivadas, indicadores de desempenho (KPIs) e segmentações demográficas e comportamentais. A derivação dessas variáveis permite uma análise mais profunda sobre padrões temporais, financeiros e de comportamento dos usuários, viabilizando futuras modelagens estatísticas e dashboards gerenciais.

Processo Implementado

A etapa foi dividida em cinco grandes blocos funcionais, que se complementam na construção de uma visão 360° dos dados:

Criação de Variáveis Temporais

Inicialmente, o código verifica a presença da coluna **data** no DataFrame e a converte para o formato datetime, assegurando consistência temporal.

A partir dessa variável, são extraídas novas dimensões de tempo:

- **Ano (ano), mês (mes), dia (dia), semana do ano (semana_ano) e trimestre (trimestre);**
- **Dia da semana (dia_semana) e nome do dia (nome_dia_semana),** úteis para identificar padrões de comportamento em dias específicos;
- **Mês/Ano (mes_ano),** que agrega os registros em formato periódico mensal.

Essas variáveis permitem análises temporais mais refinadas, como sazonalidade e evolução de KPIs ao longo do tempo.

Cálculo de KPIs Financeiros (CFO)

Nesta fase, são gerados indicadores financeiros fundamentais para a compreensão da rentabilidade e desempenho econômico das operações.

Os principais KPIs criados são:

- **Margem PicMoney (margem_picmoney):**

Calculada pela razão entre o valor de repasse da PicMoney e o valor do cupom ($\text{repasse_picmoney} / \text{valor_cupom}$).

O código trata valores nulos e infinitos para evitar distorções, apresentando posteriormente média e mediana do indicador.

- **Percentual de Desconto do Cupom (pct_desconto_cupom):**

Obtido pela relação entre o valor do cupom e o valor da compra ($\text{valor_cupom} / \text{valor_compra} * 100$), expressando a atratividade dos descontos oferecidos.

- **Valor Líquido PicMoney (valor_liquido_picmoney):**

Representa o ganho líquido da plataforma após repasses, definido como a diferença entre o valor do cupom e o repasse ($\text{valor_cupom} - \text{repasse_picmoney}$).

Esses KPIs permitem avaliar a eficiência operacional e a lucratividade da empresa sob a ótica financeira.

KPIs de Negócio (CEO)

Nesta subseção, são criadas métricas de gestão estratégica voltadas ao desempenho comercial:

- **Ticket Médio (ticket_medio_compra):** valor médio gasto por compra, obtido diretamente das variáveis financeiras consolidadas.

- **Repasse Real (repasse_real):** indicador simplificado que replica o valor de repasse_picmoney, facilitando análises comparativas e projeções futuras.

Essas métricas auxiliam na mensuração do comportamento de compra e na eficiência da política de repasses da empresa.

Variáveis Demográficas Derivadas

Com base na variável **idade**, são criadas duas novas variáveis categóricas:

- **Faixa Etária (faixa_etaria)**, segmentada em intervalos fixos (<18, 18–25, 26–35, 36–45, 46–60, 60+);
- **Segmento de Idade (segmento_idade)**, simplificação em três grupos: *Jovem*, *Adulto* e *Sênior*.

Essas classificações são essenciais para entender o perfil de público atendido e identificar oportunidades de personalização de campanhas e serviços.

Variáveis de Comportamento

Nesta fase, são adicionadas variáveis que descrevem o padrão de interação dos usuários com a plataforma:

- **Frequência de Transações (qtd_transacoes)**:
Calculada a partir do número de registros por celular, identificando quantas vezes cada usuário realizou transações.
- **Perfil de Usuário (perfil_usuario)**:
Classificação automática dos usuários conforme sua frequência, em quatro categorias: *Ocasional*, *Regular*, *Frequente* e *VIP*.

Essas variáveis possibilitam análises comportamentais e de retenção de clientes.

Resultados e Validação

Ao término da execução, o sistema gera um relatório descritivo das variáveis criadas, organizadas por categoria: O código finaliza apresentando estatísticas descritivas dos principais KPIs — média, mediana, desvio padrão, valores mínimos e máximos —, além do uso de memória e dimensões do DataFrame resultante.

Esse processo garante padronização, consistência e capacidade analítica ampliada para as próximas etapas do projeto, como modelagem preditiva ou visualização em dashboards.

Exploração e Formato Final dos Dados

Objetivo: Esta etapa teve como objetivo analisar visualmente os indicadores-chave de desempenho (KPIs) obtidos nas fases anteriores e preparar o dataset final para integração com o Streamlit, plataforma responsável pela construção do dashboard interativo do projeto.

O foco foi observar tendências temporais de receita e usuários ativos, consolidar os resultados e garantir a exportação segura e estruturada dos dados derivados para o formato compatível (.xlsx).

Etapas Implementadas:

Análise Exploratória: Evolução Mensal dos KPIs

Inicialmente, foram extraídos e agrupados dados do *DataFrame final* (*df_final*) com base na variável temporal *mes_ano*.

Duas métricas principais foram calculadas:

- Receita Mensal (Repasse PicMoney): soma total de *repasse_picmoney* por mês;
- Usuários Ativos: contagem de valores únicos na coluna *celular*, representando o número de usuários ativos em cada período.

Esses dois indicadores foram mesclados em um único *DataFrame* (*df_kpi*), permitindo a análise conjunta de desempenho financeiro e engajamento do usuário.

A visualização gráfica foi implementada com duplo eixo Y, utilizando a biblioteca *matplotlib*:

- No eixo esquerdo, um gráfico de barras representa a evolução mensal da receita total (em vermelho);
- No eixo direito, uma linha com marcadores ilustra a variação dos usuários ativos (em azul).

Essa combinação permite uma leitura integrada entre crescimento financeiro e comportamento de uso, facilitando a identificação de períodos de alta ou baixa performance.

A formatação do gráfico incluiu:

- Rotação dos eixos X para melhor legibilidade das datas (mes_ano);
- Título descritivo (“Evolução da Receita e Usuários Ativos”);
- Ajuste de cores e transparência para clareza visual.

Exportação do Arquivo Final

Após a análise visual, o *DataFrame* consolidado (df_final) foi exportado para o formato Excel (.xlsx), através da função `to_excel()` da biblioteca pandas.

- O arquivo final foi nomeado como:
PicMoney_Dados_INTEGRADOS_PRONTOS_para_Streamlit.xlsx
- O parâmetro `index=False` foi utilizado para eliminar índices automáticos, garantindo compatibilidade com o carregamento direto no Streamlit.
- Uma estrutura de tratamento de exceções (`try/except`) foi adicionada para capturar possíveis erros de gravação ou permissão, assegurando maior robustez no processo.

Ao final, o código imprime a confirmação da exportação bem-sucedida, incluindo o total de colunas disponíveis no dataset final — informação útil para configurar corretamente o painel interativo.

Resultados Obtidos

- Indicadores Temporais: evolução da receita e dos usuários ativos obtida com clareza e coerência temporal.
- Visualização: gráfico combinado de fácil interpretação, unindo desempenho financeiro e engajamento.
- Arquivo Final: dataset completo e normalizado, pronto para ser utilizado na aplicação do Streamlit Dashboard.

O resultado desta etapa consolida o ciclo de tratamento e análise dos dados, encerrando a preparação do ambiente analítico com integração direta entre back-end (Python/pandas) e camada de visualização (Streamlit).

Simulação do arquivo final e exploração dos pedestres

Objetivo: Esta etapa teve como finalidade validar a exportação final dos dados integrados e realizar uma análise exploratória complementar voltada ao perfil demográfico dos pedestres cadastrados no sistema. O intuito foi assegurar que o *DataFrame* consolidado estivesse devidamente formatado e completo para utilização no Streamlit, além de explorar características de idade, gênero e tipo de dispositivo móvel, visando identificar possíveis padrões comportamentais e demográficos dentro da base.

Etapas Implementadas:

1. Exportação do Arquivo Final Integrado

O primeiro passo foi garantir a **geração do arquivo final consolidado** em formato .xlsx, que representa o produto principal do processo de integração e derivação de dados realizado nas etapas anteriores.

Para isso, foi utilizada a função `to_excel()` da biblioteca **pandas**, salvando o *DataFrame* `df_final` com o nome:

“PicMoney_Dados_INTEGRADOS_PRONTOS_para_Streamlit.xlsx”

Essa exportação serve como fonte direta de dados para o dashboard do Streamlit, garantindo compatibilidade entre as camadas de processamento (Python) e visualização (Streamlit).

O parâmetro `index=False` foi mantido para eliminar colunas de índice e otimizar a estrutura do arquivo.

Além disso, foi implementado um bloco de tratamento de exceções (`try/except`) para evitar falhas durante a escrita do arquivo e exibir mensagens de erro detalhadas em caso de problemas (como falta de permissão ou diretório inexistente).

A conclusão bem-sucedida imprime no console:

- Confirmação do salvamento (“ Arquivo final INTEGRADO salvo com sucesso”);

2. Exploração Demográfica dos Pedestres

Com o arquivo exportado, foi realizada uma análise exploratória descritiva sobre o *DataFrame* `df_pedestres_limpo`, contendo informações demográficas dos usuários (pedestres).

O objetivo foi compreender melhor a composição da base em termos de idade, gênero e tipo de dispositivo móvel.

- **Análise de Idade:**

Aplicou-se o método `describe()` sobre a coluna `idade`, gerando estatísticas como média, desvio-padrão, valores mínimo e máximo e quartis.

Essa análise permitiu verificar a distribuição etária dos pedestres e identificar possíveis faixas predominantes.

- **Distribuição de Gênero:**

Foi utilizado o gráfico de barras (`countplot` da biblioteca *Seaborn*) para ilustrar a frequência de pedestres conforme o sexo declarado na base (`sexo`).

O gráfico apresenta o número absoluto de indivíduos de cada gênero, facilitando a comparação visual entre os grupos.

- **Distribuição por Tipo de Celular:**

Um segundo gráfico de barras representou a variável `tipo_celular`, evidenciando a quantidade de pedestres conforme o tipo de dispositivo utilizado (ex: Android, iOS ou outros).

Esse indicador auxilia na compreensão do **perfil tecnológico** da população analisada, podendo subsidiar decisões sobre estratégias de comunicação ou desenvolvimento de aplicativos.

A visualização foi organizada em **duas subplots horizontais (1x2)**, dentro de uma mesma figura de dimensão 14x5, com títulos e rótulos descritivos para cada eixo.

O uso de `plt.tight_layout()` garantiu espaçamento equilibrado entre os gráficos, promovendo uma visualização clara e esteticamente limpa.

Resultados Obtidos:

- **Exportação Concluída:** o arquivo integrado foi gerado com sucesso, contendo todas as variáveis derivadas e pronto para uso no Streamlit.
- **Análise Etária:** obtiveram-se medidas de tendência central e dispersão da idade, revelando o perfil predominante da amostra.
- **Distribuição de Gênero e Dispositivo:** observou-se a proporção entre homens e mulheres cadastrados, bem como a prevalência de determinados tipos de celulares.

Essa etapa finalizou a fase de exploração e consolidação dos dados, garantindo integridade estrutural, coerência estatística e prontidão para visualização interativa no ambiente do dashboard.

Resumo final do dataset e exploração dos pedestres

Objetivo: Esta etapa tem como finalidade realizar uma análise descritiva e visual dos dados referentes aos pedestres após a fase de limpeza e preparação do dataset. O objetivo é compreender melhor o perfil demográfico do grupo estudado, verificando a distribuição de variáveis como idade, gênero e tipo de celular, além de confirmar a integridade e consistência das informações resultantes do processo de tratamento de dados.

Processo Implementado

A etapa é estruturada em duas partes principais:

1. Análise estatística descritiva da idade dos pedestres;
2. Visualização gráfica da distribuição de gênero e tipo de celular.

O processo inicia-se com a impressão de um cabeçalho indicativo, facilitando a identificação do início da exploração demográfica no console. Em seguida, o código executa a função `describe()` sobre a coluna `idade` do DataFrame `df_pedestres_limpo`, fornecendo medidas estatísticas como média, desvio padrão, valores mínimo e máximo, e quartis.

Após a análise textual, são gerados gráficos de barras utilizando as bibliotecas Matplotlib e Seaborn, para melhor visualização das distribuições categóricas.

- O primeiro gráfico apresenta a distribuição de gênero, mostrando a quantidade de pedestres classificados em cada categoria (ex.: masculino e feminino).
- O segundo gráfico ilustra a distribuição por tipo de celular, permitindo observar a preferência tecnológica dos participantes.

A função `plt.tight_layout()` é utilizada ao final para otimizar o espaçamento entre os gráficos, e `plt.show()` exibe as figuras de forma clara e organizada.

Resultados e Validação

Os resultados obtidos nesta etapa permitem identificar tendências e padrões demográficos no conjunto de dados de pedestres. A análise de idade fornece um panorama geral da amostra, evidenciando faixas etárias predominantes. Os gráficos complementam a visualização ao destacar a proporção entre gêneros e a distribuição de dispositivos móveis, auxiliando em inferências comportamentais e tecnológicas do público analisado. Essa exploração final é essencial para confirmar a qualidade e coerência dos dados tratados, garantindo que o dataset está pronto para ser utilizado em etapas posteriores de visualização interativa, como em dashboards ou sistemas analíticos desenvolvidos em plataformas como o Streamlit.